

PROJET D'APPRENTISSAGE AUTOMATIQUE

IFT712

PROJET DE SESSION

Classification de feuilles

*Comparaison de six familles de modèles d'apprentissage
(Kaggle Leaf Classification)*

Mouloud SERIR

Cette édition personnelle de portfolio révisé la présentation du rapport remis en avril 2026. Elle conserve le protocole, les résultats et les conclusions scientifiques de la remise archivée ; les corrections portent sur la langue, la mise en page et la traduction.

Table des matières

1	Introduction	3
1.1	Contexte	3
1.2	Objectif de l'étude	3
1.3	Organisation du rapport	3
2	Analyse exploratoire des données	3
2.1	Objectif et périmètre descriptif	3
2.2	Fiche signalétique et intégrité des données	4
2.3	Répartition des classes	4
2.4	Échelle, dispersion et forme des variables	5
2.5	Corrélations et redondance entre descripteurs	7
2.6	Réduction de dimension et organisation globale	8
2.7	Implications méthodologiques et synthèse	10
2.8	Garde-fous du protocole pour la suite	11
3	Étude des modèles	11
3.1	Modèle Perceptron	12
3.1.1	Positionnement du modèle	12
3.1.2	Exploration	12
3.1.3	Confirmation	13
3.1.4	Diagnostics descriptifs	14
3.1.5	Corroboración secundaria	16
3.2	Modèle Régression logistique	17
3.2.1	Positionnement du modèle	17
3.2.2	Exploration	17
3.2.3	Confirmation	18
3.2.4	Diagnostics descriptifs	19
3.2.5	Corroboración secundaria	20
3.3	Modèle SVM RBF	21
3.3.1	Positionnement du modèle	21
3.3.2	Exploration	22
3.3.3	Confirmation	22
3.3.4	Diagnostics descriptifs	23
3.3.5	Corroboración secundaria	25
3.4	Modèle Forêt aléatoire	26
3.4.1	Positionnement du modèle	26
3.4.2	Exploration	26
3.4.3	Confirmation	27
3.4.4	Diagnostics descriptifs	28
3.4.5	Corroboración secundaria	30
3.5	Modèle Arbre de décision	31

3.5.1	Positionnement du modèle	31
3.5.2	Exploration	31
3.5.3	Confirmation	32
3.5.4	Diagnostics descriptifs	33
3.5.5	Absence de corroboration secondaire	35
3.6	Modèle MLP	35
3.6.1	Positionnement du modèle	35
3.6.2	Exploration	35
3.6.3	Confirmation	36
3.6.4	Diagnostics descriptifs	37
3.6.5	Corroboration secondaire	39
4	Comparaison Globale et Discussion	40
4.1	Résultats confirmatoires inter-modèles	40
4.2	Stabilité relative et compromis pratique	42
4.3	Analyse transversale des erreurs	43
4.4	Corroboration secondaire sur le jeu de corroboration gelé	43
4.5	Discussion scientifique	45
5	Conclusion	45
6	Annexes	46
6.1	Statut et usage des annexes	46
6.2	Protocole détaillé et artefacts canoniques	46
6.3	Résultats détaillés par variante	47
6.4	Hyperparamètres retenus par pli externe	47
6.5	Déclaration d'utilisation de l'IA	48
7	Bibliographie	49

1 Introduction

1.1 Contexte

Le projet porte sur le jeu de données `Leaf Classification` de Kaggle, traité ici comme un problème de classification multiclasse tabulaire. Chaque feuille est décrite par des variables numériques pré-extraites plutôt que par une image brute, ce qui déplace l'enjeu vers la qualité du preprocessing, le choix du modèle et surtout la rigueur du protocole d'évaluation.

La difficulté du problème tient moins à un déséquilibre des classes qu'au rapport entre le nombre d'espèces et le faible nombre d'exemples disponibles pour chacune d'elles. Dans un tel contexte, des écarts de performance modestes peuvent être artificiellement amplifiés si l'on ne sépare pas strictement les étapes exploratoires et l'estimation confirmatoire.

1.2 Objectif de l'étude

L'objectif du rapport est de comparer six familles de modèles scikit-learn dans un cadre scientifiquement défendable : perceptron, régression logistique, SVM RBF, forêt aléatoire, arbre de décision et MLP. L'enjeu n'est pas seulement d'identifier le meilleur score, mais d'établir quels gains restent crédibles après tuning, variabilité inter-plis et vérification secondaire sur un jeu de corroboration gelé.

La lecture du rapport suit donc une logique simple : l'EDA motive les choix de pré-traitement, les chapitres modèles distinguent nettement exploration et confirmation, puis la discussion globale confronte les variantes `tuned` selon leur performance, leur stabilité et leur coût pratique.

1.3 Organisation du rapport

La section 2 présente l'analyse exploratoire des données et le cadre méthodologique retenu pour la suite. La section 3 détaille séparément les six familles de modèles. La section 4 propose la comparaison globale et la discussion scientifique, avant une conclusion brève, les annexes et la bibliographie.

2 Analyse exploratoire des données

2.1 Objectif et périmètre descriptif

L'analyse exploratoire a pour fonction de caractériser la structure du jeu de données, d'en vérifier l'intégrité et d'identifier les principales propriétés statistiques susceptibles d'influencer les choix de pré-traitement. Dans ce cadre, les constats présentés ci-dessous demeurent descriptifs : ils portent sur la distribution des observations, l'échelle des variables, la redondance entre descripteurs et l'organisation globale du nuage de points, sans préjuger du comportement d'un modèle de classification donné.

Deux précautions méthodologiques s'imposent dès cette étape. D'une part, la présence d'une structure visible dans les corrélations ou dans les projections de dimension réduite ne constitue pas une preuve de séparabilité robuste. D'autre part, les hypothèses de preprocessing suggérées par cette section doivent être lues comme des pistes raisonnables d'expérimentation, et non comme des conclusions confirmatoires.

2.2 Fiche signalétique et intégrité des données

Le jeu de données d'apprentissage comprend 990 observations et 194 colonnes, dont 192 variables explicatives numériques, un identifiant `id` et une étiquette de classe `species`. Les descripteurs sont répartis en trois familles de même taille, `margin`, `shape` et `texture`, chacune comportant 64 variables. Cette structuration est importante pour l'interprétation de l'EDA, car elle permet de distinguer les phénomènes de redondance internes à une famille des dépendances plus faibles entre familles.

Les contrôles élémentaires d'intégrité ne révèlent pas d'anomalie majeure : aucune valeur manquante n'est observée, aucun doublon complet n'apparaît dans la table, aucun doublon strict n'est détecté sur les seules variables explicatives et l'identifiant `id` est unique pour chaque échantillon. Ces propriétés simplifient l'analyse ultérieure, puisqu'elles épargnent toute étape de nettoyage structurel avant la modélisation.

Indicateur	Valeur
Lignes	990
Colonnes	194
Variables explicatives	192
Classes	99
Variables <code>margin</code>	64
Variables <code>shape</code>	64
Variables <code>texture</code>	64
Valeurs manquantes	0
Doublons complets	0
Doublons sur les seules variables	0
<code>id</code> unique	Oui

TABLE 1 – Fiche signalétique du jeu de données

2.3 Répartition des classes

La variable cible présente une structure remarquablement régulière : les 99 espèces sont représentées par exactement 10 observations chacune. Ce point écarte tout déséquilibre de classe au sens usuel et permet d'interpréter les résumés descriptifs sans risque de domination mécanique par quelques espèces sur-représentées. En revanche, cette régularité ne signifie pas que le problème est simple. Avec seulement 10 feuilles par espèce, chaque classe demeure faiblement documentée, ce qui laisse présager une variabilité non négligeable des estimations des performances lorsque l'on passera à l'évaluation.

Métrique	Valeur
Minimum par classe	10
Maximum par classe	10
Moyenne par classe	10.0
Écart-type	0.0

TABLE 2 – Résumé de la répartition des classes




FIGURE 1 – Nombre d’observations par espèce. L’uniformité de la hauteur des barres confirme l’absence de déséquilibre entre classes dans l’échantillon d’apprentissage.

2.4 Échelle, dispersion et forme des variables

L’examen des distributions marginales montre que les trois familles de variables n’occupent pas les mêmes ordres de grandeur. Les variables **shape** évoluent dans un intervalle très resserré, avec une moyenne des écarts-types de 0.00029, alors que les variables **margin** et **texture** affichent respectivement 0.01688 et 0.02696. Cette hétérogénéité d’échelle est scientifiquement importante, car elle affecte directement les méthodes sensibles à la norme des variables ou à la géométrie du nuage de points.

Les boxplots jouent ici un rôle central. Contrairement à un simple tableau de moyennes, ils renseignent simultanément sur la médiane, la dispersion interquartile, l’asymétrie et la présence de valeurs extrêmes. Dans ce jeu de données, ils montrent que la famille **texture** concentre la plus forte dispersion, tandis que **shape** reste beaucoup plus contractée. Cette lecture ne permet pas d’affirmer qu’une standardisation améliorera nécessairement toutes les procédures d’apprentissage, mais elle fournit une justification descriptive solide à l’examen de variantes avec mise à l’échelle.

Famille	Min	Max	Q1 moy.	Médiane moy.	Q3 moy.	Moy. des moy.	Moy. écart-types
margin	0.00000	0.38867	0.00354	0.01028	0.02237	0.01562	0.01688
shape	0.00002	0.00301	0.00041	0.00056	0.00073	0.00061	0.00029
texture	0.00000	0.85352	0.00072	0.00543	0.01871	0.01563	0.02696

TABLE 3 – Statistiques descriptives par famille de variables




FIGURE 2 – Boxplots de variables sélectionnées dans les familles **margin**, **shape** et **texture**. La comparaison visuelle souligne l’hétérogénéité d’échelle et la dispersion plus marquée des variables de texture.

La forme des distributions confirme cette lecture. La skewness absolue moyenne des 192 variables atteint environ 2.20, avec un maximum proche de 10.91, ce qui indique des distributions souvent asymétriques et parfois fortement concentrées près de zéro. Ce résultat invite à la prudence dans l’interprétation de statistiques purement moyennes et renforce l’intérêt de descriptions robustes fondées sur les quartiles et les boxplots.

2.5 Corrélations et redondance entre descripteurs

L'étude de la matrice de corrélation met en évidence une structure en blocs nette. La famille **shape** est de loin la plus redondante, avec une corrélation absolue moyenne intra-famille de 0.6996, contre 0.2606 pour **margin** et 0.1612 pour **texture**. Les dépendances inter-familles demeurent faibles, comprises entre 0.0548 et 0.0781, ce qui suggère que les trois familles ne capturent pas exactement la même information descriptive.

Bloc	Corrélation absolue moyenne
shape-shape	0.6996
margin-margin	0.2606
texture-texture	0.1612
margin-shape	0.0675
margin-texture	0.0781
shape-texture	0.0548

TABLE 4 – Corrélation absolue moyenne intra- et inter-familles

Rang	Paire	Corrélation
1	shape49 - shape50	0.9939
2	shape17 - shape18	0.9939
3	shape15 - shape16	0.9937
4	shape16 - shape17	0.9936
5	shape18 - shape19	0.9936

TABLE 5 – Paires de variables les plus corrélées

Au total, 445 paires de variables présentent une corrélation absolue au moins égale à 0.90, et 197 une corrélation au moins égale à 0.95. Ces ordres de grandeur justifient l'examen d'une réduction de dimension par PCA, mais sans présumer de son utilité effective pour les étapes ultérieures d'apprentissage.




FIGURE 3 – Matrice de corrélation des 192 variables. La structure en blocs fait apparaître une redondance interne particulièrement forte au sein de la famille **shape**, alors que les liaisons entre familles restent plus faibles.

2.6 Réduction de dimension et organisation globale

La PCA a été appliquée sur les données standardisées afin de résumer la structure linéaire du jeu de données. Les deux premières composantes expliquent environ 24.2 % et 10.4 % de la variance totale, soit un peu moins de 34.6 % à elles seules. Les cinq premières composantes atteignent 50.7 %, et les dix premières 64.7 %. La réduction est donc réelle, mais elle n'est pas assez radicale pour suggérer qu'un espace de très faible dimension suffirait à résumer adéquatement l'information.

Les seuils de variance cumulée confirment cette lecture. Il faut 23 composantes pour atteindre 80 % de variance expliquée, 44 pour 90 %, 69 pour 95 % et 116 pour 99 %. Ainsi, la PCA peut être défendue comme outil de compression modérée et d'atténuation de la redondance linéaire, mais non comme réduction drastique du problème.

Variance expliquée cumulée	Nombre de composantes
80 %	23
90 %	44
95 %	69
99 %	116

TABLE 6 – Nombre de composantes pour différents seuils de variance




FIGURE 4 – Variance expliquée cumulée après standardisation. La croissance progressive de la courbe indique qu’une grande partie de l’information est compressible, mais qu’un nombre substantiel de composantes demeure nécessaire pour conserver presque toute la variance.

La projection **t-SNE** en deux dimensions complète cette lecture sous un angle non linéaire. Dans le notebook, elle est calculée après une réduction préalable par PCA à 50 composantes, avec une perplexité de 30. Son intérêt n’est pas de résumer quantitativement la variance, mais d’examiner la cohérence locale des voisinages entre observations. La figure fait apparaître des regroupements partiels et des zones de chevauchement, ce qui suggère une structure exploitable sans laisser attendre une séparation triviale des 99 espèces dans un espace de très basse dimension.

Cette interprétation doit rester prudente. La **t-SNE** préserve avant tout des relations de proximité locales et dépend de ses hyperparamètres ; elle ne fournit ni une mesure de séparabilité globale ni un argument suffisant pour privilégier un prétraitement particulier. Elle a ici une valeur heuristique : elle confirme l’existence d’une organisation du nuage de points au-delà du bruit pur, sans permettre d’en déduire la difficulté exacte de la tâche.




FIGURE 5 – Projection t -SNE 2D des 99 espèces après standardisation et réduction préalable par PCA. La présence de regroupements locaux coexiste avec des chevauchements importants, compatibles avec un problème apprenable mais loin d’être trivial.

2.7 Implications méthodologiques et synthèse

Quatre enseignements se dégagent de cette analyse exploratoire. Premièrement, le jeu de données est structurellement sain et parfaitement équilibré, mais il reste parcimonieux au niveau de chaque espèce, ce qui invite à la retenue dans l’interprétation des variations observées sur de petits sous-ensembles. Deuxièmement, les différences d’échelle et de dispersion entre familles fournissent une motivation descriptive forte pour examiner des procédures de standardisation. Troisièmement, la redondance marquée, surtout dans **shape**, rend méthodologiquement plausible l’étude d’une PCA comme outil de compression linéaire. Quatrièmement, les projections de dimension réduite indiquent l’existence d’une structure exploitable, tout en rappelant que cette structure n’équivaut pas à une séparabilité simple.

En conséquence, les choix de prétraitement qui seront examinés par la suite peuvent être scientifiquement motivés par cette EDA, mais ils demeurent hypothétiques à ce stade. La standardisation et la PCA apparaissent comme des options raisonnables d’exploration, non comme des garanties d’amélioration.

2.8 Garde-fous du protocole pour la suite

Les constats descriptifs précédents justifient un protocole prudent pour la comparaison des modèles. Le corpus est équilibré, mais chaque espèce reste faiblement documentée ; il serait donc méthodologiquement risqué de mélanger sélection de variantes, tuning et évaluation finale sur un même sous-ensemble. Pour cette raison, la suite du rapport distingue explicitement ce qui relève de l’exploration, de la confirmation et de la corroboration secondaire.

Élément	Valeur retenue
Split gelé	80 % développement / 20 % corroboration
Taille développement	792
Taille du jeu de corroboration	198
Validation croisée principale	5 plis externes
Tuning interne	3 plis internes
Métrique principale	F1-macro
Métrique secondaire	Accuracy
Seed globale	42
Statut des variantes non tuned	Exploratoire
Statut des variantes tuned	Confirmatoire
Statut du jeu de corroboration	Corroboration secondaire

TABLE 7 – Garde-fous du protocole expérimental

Cette hiérarchie des preuves guidera toute la lecture des sections suivantes. Les variantes non **tuned** documentent l’effet du preprocessing et du tuning, les résultats **tuned** fondent le classement principal, et le jeu de corroboration gelé n’intervient qu’en vérification secondaire.

3 Étude des modèles

Cette section compare six familles de modèles dans un cadre expérimental strictement commun. La métrique principale est le **F1-macro**, retenu pour donner le même poids aux 99 espèces, et l’**accuracy** joue le rôle de métrique secondaire.

La lecture suit trois niveaux de preuve bien distincts. Les variantes exploratoires relèvent d’une validation croisée simple et servent à mesurer l’effet du prétraitement ou du contrôle de complexité. Le résultat principal de chaque famille est la variante **tuned**, évaluée par validation croisée imbriquée. Lorsque disponible, la corroboration secondaire sur le split gelé sert uniquement à vérifier si le signal observé sur le jeu de développement se maintient sur des données jamais vues pendant la modélisation.

Les sous-chapitres qui suivent reprennent une structure commune. Chaque modèle est d’abord replacé dans la logique scientifique de l’étude, puis analysé successivement sous l’angle exploratoire, confirmatoire et, quand elle existe, de la corroboration secondaire.

L’objectif de cette partie n’est donc pas encore de trancher globalement entre les modèles, mais de comprendre comment chaque famille réagit au prétraitement, au contrôle de complexité et au tuning. La synthèse inter-modèles est volontairement réservée à la section suivante, afin de maintenir une séparation nette entre l’analyse propre à chaque famille et la comparaison transversale finale.

3.1 Modèle Perceptron

3.1.1 Positionnement du modèle

Le perceptron constitue la baseline linéaire minimale de l’étude. Son intérêt est moins de rivaliser avec les meilleurs modèles que de quantifier ce qu’une frontière de décision élémentaire peut extraire d’un problème multiclassés de grande dimension. Il fournit ainsi un point de comparaison utile pour mesurer l’effet de la standardisation et, plus généralement, le besoin de capacité supplémentaire.

3.1.2 Exploration

La phase exploratoire montre d’emblée que le prétraitement joue un rôle central pour cette famille. La variante brute atteint un **F1-macro** de 0.6979 et une **accuracy** de 0.7436. L’ajout du **StandardScaler** fait progresser le **F1-macro** à 0.8228, tandis que la variante **scaled_pca** s’établit à 0.8057. Le gain principal provient donc de la mise à l’échelle ; la réduction de dimension ne fournit pas ici d’amélioration supplémentaire robuste.

Variante	Protocole	F1-macro	Accuracy	Gap F1	Temps (s)
default	simple CV	0.6979	0.7436	0.1202	0.62
scaled_only	simple CV	0.8228	0.8460	0.1732	0.60
scaled_pca	simple CV	0.8057	0.8346	0.1923	0.65

TABLE 8 – Comparaison des variantes du perceptron

Le perceptron devient donc nettement plus crédible après normalisation, mais la taille du gap de généralisation indiqué que sa marge d’amélioration demeure limitée. Cette lecture exploratoire suggère déjà qu’un modèle linéaire non probabiliste de faible capacité restera plutôt une borne inférieure qu’un candidat de premier rang.




FIGURE 6 – Comparaison exploratoire des variantes du perceptron. Le saut de performance est presque entièrement expliqué par la standardisation des variables.

3.1.3 Confirmation

L'évaluation confirmatoire par validation croisée imbriquée conduit à un **F1-macro** moyen de 0.8085 et une **accuracy** moyenne de 0.8409, avec des écarts-types de 0.0523 et 0.0411. Le score confirmatoire reste légèrement inférieur à celui de la meilleure variante exploratoire (**scaled_only**), ce qui est cohérent avec une estimation moins optimiste après sélection de modèle.

Métrique confirmatoire	Valeur
F1-macro moyen	0.8085
Écart-type F1	0.0523
Accuracy moyenne	0.8409
Écart-type accuracy	0.0411
Protocole	nested CV
Plis externes	5
Plis internes	3
Temps total (s)	29.79

La conclusion scientifique reste stable : le perceptron capte une partie substantielle de la structure du problème une fois les variables standardisées, mais il reste nettement en retrait des meilleures familles. Il remplit donc pleinement son rôle de baseline linéaire minimale sans devenir un candidat crédible pour le classement final.

3.1.4 Diagnostics descriptifs

Les figures associées au perceptron sont avant tout descriptives. L’histogramme de la fonction de décision renseigne sur la dispersion des scores marginaux, tandis que la matrice de confusion et le tableau des principales confusions montrent que les erreurs résiduelles restent relativement diffuses, ce qui est compatible avec les limites d’une frontière linéaire simple sur un problème à 99 classes.




FIGURE 7 – Histogramme exploratoire de la fonction de décision du perceptron. La dispersion des scores reste compatible avec une séparation linéaire utile mais encore limitée.




FIGURE 8 – Matrice de confusion normalisée obtenue à partir des prédictions hors pli de la variante **tuned**. Les erreurs résiduelles restent plus diffuses que pour les meilleures familles du projet.




FIGURE 9 – Principales confusions observées pour le perceptron ajusté. Leur dispersion confirme que le modèle reste limité par sa capacité de séparation.

3.1.5 Corroboracion secundaria

Une corroboracion secundaria est disponible sur le split gelé. La variante de référence est `scaled_only`, choisie à partir des résultats exploratoires sur le jeu de développement. Sur la corroboracion, cette référence atteint un F1-macro de 0.8815, contre 0.8694 pour la variante `tuned`. Le delta `tuned - reference` est donc de -0.0121.

Variante	F1 corroboracion	Accuracy corroboracion	Rôle
default	0.8318	0.8586	baseline
scaled_only	0.8815	0.8939	référence
scaled_pca	0.8671	0.8838	descriptif
tuned	0.8694	0.8838	ajusté

Pour le perceptron, la corroboracion confirme surtout que le gain utile provient de la standardisation. Le tuning n'apporte pas d'amélioration robuste sur cette famille peu flexible, qui conserve donc avant tout le statut de baseline linéaire informative.




FIGURE 10 – Comparaison secondaire entre la variante de référence et la variante `tuned` du perceptron sur le jeu de corroboration.

3.2 Modèle Régression logistique

3.2.1 Positionnement du modèle

La régression logistique constitue la référence linéaire probabiliste du projet. Elle combine une structure de décision simple, une régularisation contrôlée et des probabilités interprétables, ce qui en fait un point d’ancrage particulièrement solide pour juger à la fois la performance prédictive et la qualité de la sortie probabiliste.

3.2.2 Exploration

Les résultats exploratoires mettent en évidence une dépendance très forte à la mise à l’échelle. Sans prétraitement, la régression logistique plafonne à 0.2591 en `F1-macro` et 0.3106 en `accuracy`. Avec `StandardScaler`, elle bondit à 0.9798 en `F1-macro` et 0.9861 en `accuracy`. La variante `scaled_pca` reste quasiment au même niveau (0.9784 en `F1-macro`), sans gain robuste par rapport au scaling seul.

Variante	Protocole	F1-macro	Accuracy	Gap F1	Temps (s)
<code>default</code>	simple CV	0.2591	0.3106	0.0899	1.69
<code>scaled_only</code>	simple CV	0.9798	0.9861	0.0202	8.10
<code>scaled_pca</code>	simple CV	0.9784	0.9848	0.0216	2.21

Cette phase suffit déjà à établir un résultat fort : sur ce jeu de données, un modèle linéaire bien régularisé devient extrêmement performant dès qu’il est alimenté par des

variables correctement standardisées. La famille se place donc immédiatement parmi les principales candidates au classement final.




FIGURE 11 – Comparaison exploratoire des variantes de régression logistique. Le scaling transforme un modèle linéaire faible en l’un des classifieurs les plus performants de l’étude.

3.2.3 Confirmation

La validation croisée imbriquée confirme pleinement cette lecture. La variante **tuned** atteint un **F1-macro** moyen de 0.9787 et une **accuracy** moyenne de 0.9848, avec des écarts-types de 0.0198 et 0.0146. L’estimation confirmatoire est pratiquement identique à celle de la meilleure variante exploratoire, ce qui traduit une excellente stabilité du signal.

Métrique confirmatoire	Valeur
F1-macro moyen	0.9787
Écart-type F1	0.0198
Accuracy moyenne	0.9848
Écart-type accuracy	0.0146
Protocole	nested CV
Plis externes	5
Plis internes	3
Temps total (s)	77.05

La régression logistique se situe en tête des moyennes confirmatoires et forme avec le SVM le duo de tête du rapport. Sa force ne vient pas d’un tuning complexe, mais

d'une adéquation remarquable entre régularisation linéaire, standardisation et structure du problème.

3.2.4 Diagnostics descriptifs

Les diagnostics associés à cette famille éclairent pourquoi elle se comporte si bien. Le chemin de régularisation montre que la performance se stabilise rapidement dans la zone utile de $\mathcal{C}$, ce qui suggère une frontière déjà bien déterminée par les données une fois le scaling appliqué. Les principales confusions résiduelles restent, quant à elles, très peu nombreuses au regard du niveau de performance observé.




FIGURE 12 – Matrice de confusion normalisée issue des prédictions hors pli de la variante **tuned**. La quasi-diagonale confirme une excellente séparabilité inter-classes.




FIGURE 13 – Diagnostic exploratoire du compromis entre régularisation et performance. Cette figure aide à interpréter le modèle, sans remplacer l'estimation confirmatoire.




FIGURE 14 – Principales confusions résiduelles de la régression logistique. Leur faible nombre est cohérent avec le niveau de performance confirmatoire observé.

3.2.5 Corroboracion secundaria

La corroboracion secundaria confirma integralmente la lectura principal. La referencia `scaled_only`, la variante `scaled_pca` et la variante `tuned` obtiennent toutes 0.9892 en

F1-macro et 0.9899 en accuracy sur le split gelé. Le delta `tuned - reference` est donc nul.

Variante	F1 corroboration	Accuracy corroboration	Rôle
default	0.4800	0.5253	baseline
scaled_only	0.9892	0.9899	référence
scaled_pca	0.9892	0.9899	descriptif
tuned	0.9892	0.9899	ajusté

Pour la régression logistique, la corroboration prolonge un constat déjà net dans les analyses précédentes : après standardisation, la famille est à la fois très performante et remarquablement stable. C'est cette combinaison, plus encore que le tuning lui-même, qui en fait la référence pratique du rapport.




FIGURE 15 – Comparaison secondaire entre la variante de référence et la variante `tuned` de la régression logistique sur le jeu de corroboration.

3.3 Modèle SVM RBF

3.3.1 Positionnement du modèle

Le SVM à noyau RBF représente l'hypothèse non linéaire de référence parmi les méthodes à marge. Son intérêt est de vérifier si une frontière plus souple que celle des modèles linéaires peut apporter un gain tangible, tout en restant contrôlée sur un jeu de données de taille modérée.

3.3.2 Exploration

Le SVM se montre déjà solide sans prétraitement, avec un **F1-macro** de 0.8389 et une **accuracy** de 0.8561. La standardisation change toutefois nettement d'échelle : les variantes **scaled_only** et **scaled_pca** atteignent toutes deux 0.9712 en **F1-macro** et 0.9785 en **accuracy**. La PCA ne modifie donc pas la lecture empirique, alors que le scaling apparaît comme la condition décisive pour exploiter efficacement le noyau RBF.

Variante	Protocole	F1-macro	Accuracy	Gap F1	Temps (s)
default	simple CV	0.8389	0.8561	0.1364	2.36
scaled_only	simple CV	0.9712	0.9785	0.0266	2.45
scaled_pca	simple CV	0.9712	0.9785	0.0266	2.50

Dès la phase exploratoire, le SVM rejoint ainsi le groupe de tête. Il combine une très forte performance à un écart de généralisation limité, ce qui justifie pleinement sa présence parmi les modèles centraux de l'étude.




FIGURE 16 – Comparaison exploratoire des variantes du SVM. Le noyau RBF devient pleinement compétitif après standardisation des variables.

3.3.3 Confirmation

La validation croisée imbriquée confirme cette position de premier plan. La variante **tuned** atteint un **F1-macro** moyen de 0.9756 et une **accuracy** moyenne de 0.9823, avec des écarts-types de 0.0207 et 0.0151. Le score confirmatoire est légèrement supérieur à celui des meilleures variantes exploratoires, ce qui suggère un tuning utile mais modéré.

Métrique confirmatoire	Valeur
F1-macro moyen	0.9756
Écart-type F1	0.0207
Accuracy moyenne	0.9823
Écart-type accuracy	0.0151
Protocole	nested CV
Plis externes	5
Plis internes	3
Temps total (s)	56.49

Le SVM appartient lui aussi au duo de tête confirmatoire, avec une moyenne très proche de celle de la régression logistique. Il offre donc une alternative non linéaire de très haut niveau, au prix d'un coût d'entraînement plus élevé et d'une moindre interprétabilité structurelle.

3.3.4 Diagnostics descriptifs

Le tableau de tuning exploratoire montre que les meilleures performances se concentrent dans une zone compacte de l'espace des hyperparamètres. Deux constats dominant. Le réglage `gamma = 0.1` dégrade fortement les scores. De plus, la PCA n'apporte pas de gain robuste face au pipeline standardisé sans réduction de dimension. Le meilleur réglage exploratoire reste donc `C = 10` avec `gamma = scale`, sans PCA.

C / gamma	scale	0.01	0.1
1	0.9697	0.9693	0.2539
10	0.9700	0.9679	0.2885

TABLE 9 – Tuning exploratoire du SVM sans PCA (F1-macro moyen de CV)

C / gamma	scale	0.01	0.1
1	0.9697	0.9679	0.2917
10	0.9688	0.9654	0.3402

TABLE 10 – Tuning exploratoire du SVM avec PCA (F1-macro moyen de CV)

Les confusions résiduelles restent rares et localisées, ce qui est compatible avec la qualité du score confirmatoire.




FIGURE 17 – Matrice de confusion normalisée issue des prédictions hors pli de la variante tuned. Les erreurs résiduelles sont peu nombreuses et concentrées.




FIGURE 18 – Principales confusions du SVM ajusté. Leur nombre limité indique que les erreurs se concentrent sur quelques cas structurellement difficiles.

3.3.5 Corroboration secondaire

La corroboration secondaire va dans le même sens que l'analyse confirmatoire, avec un signal plus favorable encore au tuning. La référence `scaled_only` obtient 0.9838 en F1-macro et 0.9848 en accuracy, tandis que la variante `tuned` atteint 0.9946 et 0.9949. Le `delta tuned - reference` est donc de +0.0108.

Variante	F1 corroboration	Accuracy corroboration	Rôle
default	0.9242	0.9343	baseline
scaled_only	0.9838	0.9848	référence
scaled_pca	0.9838	0.9848	descriptif
tuned	0.9946	0.9949	ajusté

Pour le SVM, la corroboration conserve une utilité pratique visible : le tuning y demeure favorable sur le split gelé. La famille apparaît ainsi comme l'une des solutions les plus convaincantes du rapport, très proche de la régression logistique en niveau mais plus dépendante d'un réglage fin.




FIGURE 19 – Comparaison secondaire entre la variante de référence et la variante `tuned` du SVM sur le jeu de corroboration.

3.4 Modèle Forêt aléatoire

3.4.1 Positionnement du modèle

La forêt aléatoire représente la famille d'ensembles arborescents du projet. Elle est particulièrement intéressante ici parce qu'elle peut capter des interactions non linéaires sans exiger de mise à l'échelle, et parce qu'elle stabilise les coupures que l'arbre de décision unique peine à généraliser.

3.4.2 Exploration

La lecture exploratoire est très favorable à cette famille. La variante `default` atteint 0.9764 en F1-macro et 0.9785 en accuracy, avec un gap de généralisation contenu (0.0236). La variante `restricted_depth`, ajoutée comme contrôle de complexité, descend à 0.9345 en F1-macro et 0.9445 en accuracy. Restreindre la profondeur réduit donc légèrement le temps de calcul mais dégrade nettement la performance.

Variante	Protocole	F1-macro	Accuracy	Gap F1	Temps (s)
<code>default</code>	simple CV	0.9764	0.9785	0.0236	9.16
<code>restricted_depth</code>	simple CV	0.9345	0.9445	0.0651	5.42

Des ce stade, la forêt aléatoire se place parmi les meilleurs modèles du projet. Sa force principale tient au fait qu'elle atteint ce niveau sans prétraitement sophistiqué, ce qui

en fait une option robuste et simple a mobiliser sur des variables tabulaires déjà bien informatives.




FIGURE 20 – Comparaison exploratoire des variantes de forêt aléatoire. La version de base est déjà très performante et la restriction de profondeur se révèle trop coûteuse en termes de performance.

3.4.3 Confirmation

La validation croisée imbriquée aboutit à un F1-macro moyen de 0.9702 et une accuracy moyenne de 0.9747, avec des écarts-types de 0.0140 et 0.0089. Le score confirmatoire reste légèrement inférieur a celui de la meilleure variante exploratoire, ce qui est attendu dès lors que l'estimation corrige l'optimisme de la sélection.

Métrique confirmatoire	Valeur
F1-macro moyen	0.9702
Écart-type F1	0.0140
Accuracy moyenne	0.9747
Écart-type accuracy	0.0089
Protocole	nested CV
Plis externes	5
Plis internes	3
Temps total (s)	250.11

La forêt aléatoire se maintient ainsi dans le trio de tête. Elle est légèrement derriere la régression logistique et le SVM, mais elle demeure très compétitive et remarquablement

stable. Son principal coût tient au temps d'entraînement plus élevé que celui des modèles linéaires.

3.4.4 Diagnostics descriptifs

La courbe OOB montre que le gain marginal se stabilise rapidement quand le nombre d'arbres augmente. Cette lecture est pleinement cohérente avec la bonne tenue de la variante `default` et avec le caractère progressif, plutôt que disruptif, du tuning. Les figures de confusion confirment par ailleurs que les erreurs résiduelles restent rares et structurées.




FIGURE 21 – Évolution exploratoire du score OOB selon le nombre d'arbres. La courbe suggère une stabilisation rapide de la performance lorsque la forêt est suffisamment grande.




FIGURE 22 – Matrice de confusion normalisée obtenue à partir des prédictions hors pli de la variante **tuned**. Le motif reste très proche de celui des meilleurs modèles du projet.




FIGURE 23 – Principales confusions résiduelles de la forêt aléatoire. Leur volume limité confirme la forte séparabilité effective du problème pour cette famille.

3.4.5 Corroboracion secondaire

Une corroboracion secondaire est disponible sur le split gelé. La référence retenue est la variante `default`, choisie à partir des résultats exploratoires sur le jeu de développement. Sur la corroboracion, `default` et `tuned` obtiennent exactement les mêmes scores, soit 0.9842 en F1-macro et 0.9848 en accuracy. Le delta `tuned - reference` est donc nul.

Variante	F1 corroboracion	Accuracy corroboracion	Rôle
default	0.9842	0.9848	référence
restricted_depth	0.9468	0.9545	descriptif
tuned	0.9842	0.9848	ajusté

La corroboracion confirme ici la très bonne tenue de la famille sans fournir d'argument clair en faveur d'un gain additionnel du tuning. La forêt aléatoire reste donc un modèle de premier plan, robuste et très performant, mais dont la configuration de base est déjà proche de l'optimum pratique sur ce jeu de données.




FIGURE 24 – Comparaison secondaire entre la variante de référence et la variante **tuned** de la forêt aléatoire sur le jeu de corroboration.

3.5 Modèle Arbre de décision

3.5.1 Positionnement du modèle

L'arbre de décision est étudié ici moins comme candidat final que comme point de référence sur le compromis entre interprétabilité et généralisation. Cette famille permet de lire directement l'effet de la profondeur, de la taille de feuille et de l'élégage, mais elle est aussi particulièrement exposée au sur-apprentissage dans un problème multiclassés riche.

3.5.2 Exploration

Les deux variantes exploratoires bornent clairement le comportement de la famille. La variante **default** atteint 0.5809 en F1-macro et 0.6174 en **accuracy**, mais avec un gap de généralisation très élevé (0.4191). À l'inverse, **restricted_depth** réduit fortement ce gap (0.0797) mais au prix d'un effondrement de la performance, avec seulement 0.1468 en F1-macro.

Variante	Protocole	F1-macro	Accuracy	Gap F1	Temps (s)
default	simple CV	0.5809	0.6174	0.4191	1.04
restricted_depth	simple CV	0.1468	0.1529	0.0797	0.56

La conclusion exploratoire est donc sans ambiguïté : un arbre trop libre mémorise les données, tandis qu'un arbre trop contraint perd l'essentiel de son pouvoir discriminant. L'espace utile de la famille existe, mais il paraît étroit et instable.




FIGURE 25 – Comparaison exploratoire des variantes de l’arbre de décision. Le compromis performance-complexité reste globalement défavorable à un arbre unique.

3.5.3 Confirmation

La validation croisée imbriquée confirme cette fragilité. La variante `tuned` obtient un **F1-macro** moyen de 0.4295 et une **accuracy** moyenne de 0.4610, avec des écarts-types de 0.0546 et 0.0627. Le recul par rapport à la variante `default` ne signifie pas que le tuning détériore le modèle ; il signale surtout qu’une estimation confirmatoire plus stricte corrige l’optimisme de l’évaluation simple sur un estimateur très instable.

Métrique confirmatoire	Valeur
F1-macro moyen	0.4295
Écart-type F1	0.0546
Accuracy moyenne	0.4610
Écart-type accuracy	0.0627
Protocole	nested CV
Plis externes	5
Plis internes	3
Temps total (s)	11.47

L’arbre de décision se place ainsi très loin derrière les autres familles. Il reste pédagogiquement utile pour lire les mécanismes de sur-apprentissage, mais il ne constitue pas une solution compétitive dans le cadre de ce projet.

3.5.4 Diagnostics descriptifs

La courbe de validation selon `max_depth` expose directement le cœur du problème : le score d'entraînement augmente vite avec la profondeur, alors que le score de validation plafonne puis se dégrade. Les matrices de confusion montrent en conséquence un motif beaucoup plus diffus que celui observé pour les meilleurs modèles.




FIGURE 26 – Courbe de validation exploratoire selon `max_depth`. La divergence entre apprentissage et validation illustre directement la fragilité de la famille.




FIGURE 27 – Matrice de confusion normalisée issue des prédictions hors pli de la variante tuned. Les erreurs restent nombreuses et disperses.




FIGURE 28 – Principales confusions de l’arbre ajusté. Leur dispersion est cohérente avec une généralisation insuffisante sur un problème à 99 classes.

3.5.5 Absence de corroboration secondaire

Contrairement aux autres familles éligibles, aucune corroboration secondaire n’est publiée pour l’arbre de décision dans les artefacts canoniques. La lecture scientifique repose donc uniquement sur l’articulation entre exploration, confirmation et diagnostics de confusion.

Cette absence ne change pas la conclusion de fond. Même sans recours à la corroboration secondaire, les résultats confirmatoires suffisent à montrer qu’un arbre unique reste trop instable pour rivaliser avec les modèles linéaires régularisés, le SVM, la forêt aléatoire ou même le MLP.

3.6 Modèle MLP

3.6.1 Positionnement du modèle

Le MLP représente la famille neuronale dense de l’étude. Il permet de tester si une capacité non linéaire plus flexible que celle des modèles linéaires ou à noyau se traduit en gain empirique sur un jeu tabulaire de taille modérée, avec un nombre d’exemples par classe relativement faible.

3.6.2 Exploration

La phase exploratoire montre de façon très nette que le prétraitement est une condition de fonctionnement du modèle. Sans scaling, le MLP s’effondre à 0.1642 en F1-macro et 0.1863 en accuracy, avec une variabilité très forte. Une fois les variables standardisées, la variante `scaled_only` atteint 0.9389 en F1-macro et 0.9482 en accuracy, tandis que `scaled_pca` obtient 0.9323 et 0.9444.

Variante	Protocole	F1-macro	Accuracy	Gap F1	Temps (s)
default	simple CV	0.1642	0.1863	0.0262	1.97
scaled_only	simple CV	0.9389	0.9482	0.0552	2.01
scaled_pca	simple CV	0.9323	0.9444	0.0604	1.97

Le diagnostic central est donc clair : le MLP devient compétitif uniquement lorsqu'il est alimenté par un pipeline de standardisation strict. La PCA n'apporte pas de bénéfice net et reste légèrement en retrait par rapport à la variante `scaled_only`.




FIGURE 29 – Comparaison exploratoire des variantes du MLP. Le contraste entre la version brute et les versions standardisées illustre la dépendance du réseau à l'échelle des variables.

3.6.3 Confirmation

L'évaluation confirmatoire aboutit à un **F1-macro** moyen de 0.9389 et une **accuracy** moyenne de 0.9482, avec des écarts-types de 0.0322 et 0.0279. La variante `tuned` reproduit donc presque exactement la meilleure lecture exploratoire, ce qui suggère que le tuning confirme davantage une configuration déjà solide qu'il n'apporte un gain substantiel.

Métrique confirmatoire	Valeur
F1-macro moyen	0.9389
Écart-type F1	0.0322
Accuracy moyenne	0.9482
Écart-type accuracy	0.0279
Protocole	nested CV
Plis externes	5
Plis internes	3
Temps total (s)	38.25

Le MLP se place ainsi au quatrième rang du classement confirmatoire. Il reste nettement performant, mais il ne transforme pas sa flexibilité supplémentaire en avantage sur le trio composé de la régression logistique, du SVM et de la forêt aléatoire.

3.6.4 Diagnostics descriptifs

Les diagnostics associés au MLP éclairent surtout sa dynamique d'optimisation. La courbe de perte indique une convergence correcte, tandis que le tableau de tuning exploratoire montre que l'essentiel du signal vient ici de la taille de la couche cachée et non de α . La configuration (128,) domine systématiquement (64,), alors que la PCA reste légèrement en retrait. Ces diagnostics aident à comprendre le comportement du modèle, sans concurrencer les métriques confirmatoires.




FIGURE 30 – Diagnostic exploratoire de convergence du MLP. La loss se stabilise correctement, mais cette lecture reste descriptive.

hidden_layer_sizes / alpha	0.0001	0.0010
(64,)	0.9055	0.9055
(128,)	0.9341	0.9341

TABLE 11 – Tuning exploratoire du MLP sans PCA (F1-macro moyen de CV)

hidden_layer_sizes / alpha	0.0001	0.0010
(64,)	0.9107	0.9107
(128,)	0.9266	0.9266

TABLE 12 – Tuning exploratoire du MLP avec PCA (F1-macro moyen de CV)




FIGURE 31 – Matrice de confusion normalisée issue des prédictions hors pli de la variante **tuned**. Les erreurs résiduelles restent limitées, mais plus nombreuses que pour les trois meilleures familles.




FIGURE 32 – Principales confusions du MLP ajusté. Elles restent relativement concentrées et confirment un niveau globalement compétitif.

3.6.5 Corroboracion secundaria

Le jeu de corroboracion gelé conserve `scaled_only` comme référence secondaire. Sur ce split, la référence et la variante `tuned` obtiennent exactement les mêmes scores, soit 0.9785 en F1-macro et 0.9798 en accuracy. La variante `scaled_pca` reste légèrement en retrait. Le delta `tuned - reference` est donc nul.

Variante	F1 corroboracion	Accuracy corroboracion	Rôle
default	0.0080	0.0404	baseline
scaled_only	0.9785	0.9798	référence
scaled_pca	0.9737	0.9747	descriptif
tuned	0.9785	0.9798	ajusté

Le message reste simple pour le MLP : avec un prétraitement adéquat, la famille devient solide, mais le tuning n'y ajoute pas de gain robuste sur ce corpus. Elle demeure crédible sans dépasser les meilleures options plus sobres.




FIGURE 33 – Comparaison secondaire entre la variante de référence et la variante **tuned** du MLP sur le jeu de corroboration.

4 Comparaison Globale et Discussion

La comparaison inter-modèles présentée dans cette section repose exclusivement sur les variantes **tuned** évaluées par validation croisée imbriquée. Ce choix vise à limiter le biais de sélection introduit par le tuning des hyperparamètres, conformément aux recommandations classiques de la littérature sur l'évaluation des modèles (Varma and Simon, 2006 ; Cawley and Talbot, 2010). Les variantes non tunees et les diagnostics spécifiques gardent un rôle interprétatif, tandis que le jeu de corroboration gelé reste un contrôle secondaire.

4.1 Résultats confirmatoires inter-modèles

Le tableau suivant rassemble les six familles de modèles sur la base de leur performance confirmatoire **tuned**, avec **F1-macro** comme métrique principale et **accuracy** comme métrique secondaire.

Modèle	F1-macro (mean $\pm$ std)	Accuracy (mean $\pm$ std)	Temps (s)
Régression logistique	0.9787 ± 0.0198	0.9848 ± 0.0146	77.05
SVM RBF	0.9756 ± 0.0207	0.9823 ± 0.0151	56.49
Forêt aléatoire	0.9702 ± 0.0140	0.9747 ± 0.0089	250.11
MLP	0.9389 ± 0.0322	0.9482 ± 0.0279	38.25
Perceptron	0.8085 ± 0.0523	0.8409 ± 0.0411	29.79
Arbre de décision	0.4295 ± 0.0546	0.4610 ± 0.0627	11.47

TABLE 13 – Comparaison confirmatoire inter-modèles




FIGURE 34 – Comparaison confirmatoire inter-modèles

La hiérarchie qui se dégage est nette. La régression logistique et le SVM RBF forment le duo de tête confirmatoire, avec un léger avantage moyen pour la régression logistique. La forêt aléatoire reste à un niveau très élevé, mais légèrement en retrait. Le MLP constitue une solution sérieuse sans rejoindre les trois meilleurs modèles. Le perceptron joue correctement son rôle de baseline linéaire après preprocessing, tandis que l'arbre de décision seul apparaît clairement insuffisant dans ce problème multiclasse.

Le point central de lecture est la proximité entre régression logistique et SVM. L'écart observé sur **F1-macro** moyen est faible, mais la régression logistique conserve la meilleure moyenne. En l'absence de test statistique formel entre modèles très proches, il est plus prudent de parler de co-leaders confirmatoires, avec la régression logistique en tête sur la moyenne, que de vainqueur unique au sens strict.

4.2 Stabilité relative et compromis pratique

Les écarts-types inter-plis ne constituent pas un test statistique, mais ils apportent une information utile sur la stabilité relative des familles de modèles sous le protocole retenu.

Modèle	Amplitude F1	Commentaire de stabilité
Régression logistique	0.0512	Tres bon niveau de stabilité
SVM RBF	0.0549	Stabilité proche de la régression logistique
Forêt aléatoire	0.0343	La plus stable parmi les trois meilleurs modèles
MLP	0.0896	Variabilité plus marquée
Perceptron	0.1121	Stabilité insuffisante pour viser le haut du classement
Arbre de décision	0.1449	Instabilité structurelle très forte




FIGURE 35 – Compromis temps de calcul / performance

Du point de vue pratique, la régression logistique émerge comme le meilleur compromis entre performance moyenne, coût et interprétabilité. Elle atteint le meilleur niveau confirmatoire observé tout en restant plus simple à lire qu'un SVM RBF et beaucoup moins coûteuse qu'une forêt aléatoire. Le SVM obtient un résultat très proche, mais au prix d'une interprétabilité plus faible. La forêt aléatoire confirme sa robustesse, mais son coût de calcul est de loin le plus élevé du groupe de tête.

Le MLP et le perceptron sont relativement rapides, mais cet avantage ne compense pas leur déficit de performance par rapport aux meilleurs candidats. L'arbre de décision, enfin, est certes peu coûteux, mais sa faiblesse prédictive interdit d'en faire une solution défendable dans le cadre du projet.

4.3 Analyse transversale des erreurs

Les prédictions OOF `tuned` sur le sous-ensemble de développement ($n = 792$) permettent de compléter l'analyse globale par une lecture plus fine du volume et du profil des erreurs.

Modèle	Observations correctes	Erreurs	Part d'erreurs
Régression logistique	780	12	1.5 %
SVM RBF	778	14	1.8 %
Forêt aléatoire	772	20	2.5 %
MLP	751	41	5.2 %
Perceptron	666	126	15.9 %
Arbre de décision	365	427	53.9 %

Cette lecture confirme la hiérarchie observée sur **F1-macro**. Les deux co-leaders commettent très peu d'erreurs à l'échelle du jeu de développement, la forêt aléatoire reste proche, puis l'on observe une rupture plus nette avec le MLP, le perceptron et surtout l'arbre de décision. Autrement dit, la différence entre les meilleurs modèles et les modèles plus faibles ne relève pas seulement de petites fluctuations de score : elle se traduit par un changement d'ordre de grandeur dans le nombre d'erreurs.

Le recouvrement des erreurs entre les trois meilleurs modèles apporte un complément utile à cette lecture.

Comparaison	Erreurs communes	Erreurs distinctes	Jaccard
Régression logistique vs SVM	10	16	0.625
Régression logistique vs Forêt aléatoire	5	27	0.185
SVM vs Forêt aléatoire	5	29	0.172

La régression logistique et le SVM partagent donc une partie substantielle de leurs erreurs résiduelles. Le recouvrement est même fort : 10 erreurs communes sur 16 erreurs distinctes au total, soit un Jaccard de 0.625. Cette proximité est cohérente avec leur quasi-égalité en performance et suggère qu'ils exploitent des structures discriminantes très semblables. La forêt aléatoire partage moins d'erreurs avec eux, ce qui renforce l'idée d'un profil descriptif partiellement différent, sans toutefois remettre en cause son léger retrait sur la métrique principale.

Dans l'ensemble, l'analyse transversale des erreurs suggère que les gains restants ne se jouent plus sur une séparation globale grossière, mais sur un petit nombre de cas ambigus. Les meilleurs modèles se distinguent donc moins par la nature générale du problème que par leur capacité à traiter ces régions frontières résiduelles.

4.4 Corroboration secondaire sur le jeu de corroboration gelé

Le jeu de corroboration gelé fournit une vérification externe secondaire des pipelines retenus. Il ne remplace ni la logique confirmatoire de la **nested CV**, ni la hiérarchie établie plus haut.

Modèle	Variante de référence	F1 corroboration ref	F1 corroboration tuned	Commentaire
Régression logistique	scaled_only	0.9892	0.9892	Tuning neutre sur la corroboration
SVM RBF	scaled_only	0.9838	0.9946	Tuning favorable sur la corroboration
Forêt aléatoire	default	0.9842	0.9842	Tuning neutre sur la corroboration
MLP	scaled_only	0.9785	0.9785	Tuning neutre sur la corroboration
Perceptron	scaled_only	0.8815	0.8694	Tuning légèrement défavorable sur la corroboration




FIGURE 36 – Comparaison, pour chaque modèle éligible, entre la variante de référence retenue sur le jeu de développement et la variante **tuned** sur le jeu de corroboration gelé.

Pris isolément, ces chiffres pourraient inviter à reclasser certains modèles. Une telle lecture serait méthodologiquement fautive. Le jeu de corroboration ne constitue pas ici une nouvelle phase de sélection, mais un contrôle final secondaire sur un split unique. Il confirme globalement la solidité des meilleurs pipelines, mais ne doit pas être mobilisé pour invalider la hiérarchie principale fondée sur les estimations confirmatoires en validation croisée imbriquée.

4.5 Discussion scientifique

Plusieurs enseignements généraux se dégagent de l'étude. Le premier est qu'un modèle linéaire bien régularisé peut rester extrêmement compétitif dans un problème multiclasse à forte dimension dès lors que le preprocessing est adapté. La régression logistique montre ici qu'une structure relativement sobre peut suffire à atteindre un niveau de généralisation très élevé.

Le deuxième enseignement est que le SVM RBF confirme l'existence de structures non linéaires exploitables, sans toutefois apporter de gain net mesurable par rapport à la régression logistique. Dans ce contexte, le choix entre les deux peut donc être orienté par des critères pratiques, en particulier l'interprétabilité et le coût de calcul.

Le troisième enseignement concerne la forêt aléatoire. Sa très bonne performance, obtenue sans scaling, montre qu'une approche arboricole agrégée capture elle aussi efficacement la structure du problème. En revanche, son surcoût important et son léger retrait sur **F1-macro** rendent moins naturel le choix de cette famille lorsque l'on recherche un compromis global.

Le cas du MLP est également instructif. Le modèle devient compétitif après normalisation, mais il ne dépasse pas les meilleures approches plus simples. Cette observation est cohérente avec un régime de données relativement modeste au regard de la complexité multiclasse du problème : une capacité de représentation plus élevée ne se traduit pas automatiquement par une meilleure généralisation.

Enfin, le contraste entre l'arbre de décision et la forêt aléatoire rappelle le rôle décisif de l'agrégation. L'interprétabilité d'un arbre unique ne suffit pas lorsque la variance du modèle devient trop forte. Ici, l'arbre seul constitue surtout un contrepoint utile pour montrer ce que l'ensemble corrige.

En synthèse, le projet montre surtout qu'un modèle linéaire bien régularisé peut rester très compétitif dès lors que le preprocessing est adapté. Les gains apportés par des modèles plus flexibles restent ici modestes et doivent être jugés à la lumière de leur coût, de leur stabilité et de leur lisibilité.

5 Conclusion

Cette étude visait à comparer six familles de modèles sur le jeu de données **Leaf Classification** dans un cadre séparant explicitement exploration, confirmation et corroboration secondaire. Le classement principal repose sur les variantes **tuned** évaluées par validation croisée imbriquée, avec **F1-macro** comme métrique de référence.

Les résultats confirment un duo de tête constitué de la régression logistique et du SVM RBF, avec un léger avantage moyen pour la régression logistique et une forêt aléatoire très proche en soutien. Le MLP reste crédible sans rejoindre ce trio, tandis que le perceptron et surtout l'arbre de décision demeurent en retrait.

Du point de vue pratique, la régression logistique apparaît comme le choix le plus défendable, car elle combine le meilleur score moyen observé, un coût de calcul modéré et une interprétabilité supérieure à celle des alternatives non linéaires les plus proches. Le jeu de corroboration gelé soutient globalement cette lecture sans la redéfinir.

Cette conclusion reste toutefois située : elle repose sur un seul jeu de données, sans validation externe indépendante, et sur un unique schéma de validation croisée imbriquée. Les prolongements les plus naturels consistent donc à répéter l'évaluation sur plusieurs répartitions, à tester la robustesse des conclusions sur des données externes et à approfondir

l'analyse des erreurs résiduelles communes aux meilleurs modèles.

6 Annexes

6.1 Statut et usage des annexes

Les annexes rassemblent les éléments utiles à la reproductibilité, à l'audit méthodologique et à la lecture détaillée des artefacts sans alourdir le corps du rapport. Elles prolongent donc l'analyse, mais n'en déplacent pas la base inférentielle. Les conclusions principales demeurent fondées sur les variantes **tuned** évaluées en **nested_cv**; les autres informations conservées ici ont un statut descriptif, exploratoire ou documentaire selon les cas.

6.2 Protocole détaille et artefacts canoniques

Élément	Valeur retenue
Seed globale	42
Split gelé	80 % développement / 20 % corroboration
Taille développement	792
Taille du jeu de corroboration	198
Validation croisée principale	5 plis externes
Tuning interne	3 plis
Variance conservée par la PCA	0.99
Métrique principale	F1-macro
Métrique secondaire	Accuracy
Parallelisme CV	CV_N_JOBS = 1

TABLE 14 – Paramètres du protocole expérimental

La préservation d'un split gelé, distinct du sous-ensemble de développement, permet de maintenir une séparation claire entre analyse principale et corroboration secondaire. Les variantes non **tuned** servent à explorer l'effet du preprocessing et de la capacité des modèles; les variantes **tuned** constituent seules la base du classement inter-modèles.

6.3 Résultats détaillés par variante

Modèle	Variante	Statut	F1-macro val	Accuracy val	Temps (s)
perceptron	default	Exploratoire	0.6979	0.7436	0.62
perceptron	scaled_only	Exploratoire	0.8228	0.8460	0.60
perceptron	scaled_pca	Exploratoire	0.8057	0.8346	0.65
perceptron	tuned	Confirmatoire	0.8085	0.8409	29.79
regression_logistique	default	Exploratoire	0.2591	0.3106	1.69
regression_logistique	scaled_only	Exploratoire	0.9798	0.9861	8.10
regression_logistique	scaled_pca	Exploratoire	0.9784	0.9848	2.21
regression_logistique	tuned	Confirmatoire	0.9787	0.9848	77.05
svm	default	Exploratoire	0.8389	0.8561	2.36
svm	scaled_only	Exploratoire	0.9712	0.9785	2.45
svm	scaled_pca	Exploratoire	0.9712	0.9785	2.50
svm	tuned	Confirmatoire	0.9756	0.9823	56.49
foret_aleatoire	default	Exploratoire	0.9764	0.9785	9.16
foret_aleatoire	restricted_depth	Exploratoire	0.9345	0.9445	5.42
foret_aleatoire	tuned	Confirmatoire	0.9702	0.9747	250.11
arbre_decision	default	Exploratoire	0.5809	0.6174	1.04
arbre_decision	restricted_depth	Exploratoire	0.1468	0.1529	0.56
arbre_decision	tuned	Confirmatoire	0.4295	0.4610	11.47
mlp	default	Exploratoire	0.1642	0.1863	1.97
mlp	scaled_only	Exploratoire	0.9389	0.9482	2.01
mlp	scaled_pca	Exploratoire	0.9323	0.9444	1.97
mlp	tuned	Confirmatoire	0.9389	0.9482	38.25

TABLE 15 – Résultats de validation par variante

Ce tableau doit être lu en respectant le statut de chaque ligne. Les scores des variantes exploratoires servent à documenter l’effet du prétraitement et de la complexité ; ils ne doivent pas être confondus avec les scores confirmatoires des variantes **tuned**.

6.4 Hyperparamètres retenus par pli externe

La stabilité de la sélection par pli renseigne utilement sur la robustesse des familles de modèles. Certaines familles convergent vers les mêmes réglages sur presque tous les plis, tandis que d’autres montrent une variabilité plus marquée, particulièrement sur l’usage de la PCA ou sur l’intensité de la régularisation.

Modèle	Règles observées sur les 5 plis externes
perceptron	<code>alpha = 0.001</code> , <code>penalty = l1</code> sur tous les plis ; PCA retenue une seule fois, sinon <code>passthrough</code>
regression_logistique	<code>C</code> alterne entre 1.0 et 10.0 ; PCA retenue sur un seul pli, sinon <code>passthrough</code>
svm	<code>C = 10.0</code> et <code>gamma = scale</code> sur tous les plis ; PCA retenue une seule fois
foret_aleatoire	Règles presque parfaitement stables : <code>max_depth = None</code> , <code>max_features = sqrt</code> , <code>min_samples_leaf = 1</code> , <code>n_estimators = 400</code> sur tous les plis
arbre_decision	<code>max_depth = 20</code> , <code>criterion = gini</code> , <code>min_samples_leaf = 1</code> ; seul <code>ccp_alpha</code> varie, avec 0.005 sur un pli et 0.0 sinon
mlp	<code>hidden_layer_sizes = [128]</code> sur tous les plis ; <code>alpha = 0.0001</code> sur quatre plis et 0.001 sur un pli ; jamais de PCA

TABLE 16 – Hyperparamètres retenus par pli externe

La forêt aléatoire, le SVM et le MLP montrent une sélection par pli très homogène. La régression logistique et le perceptron restent plus sensibles à la régularisation linéaire et au choix éventuel d’une PCA, sans que cette variabilité remette en cause leur lecture globale. Dans le cas de l’arbre de décision, la stabilité de la profondeur ne compense pas l’instabilité prédictive observée sur les scores.

6.5 Déclaration d’utilisation de l’IA

Cette déclaration est fournie à titre de transparence documentaire. L’assistance par IA a été utilisée de manière ponctuelle au cours du projet, mais elle n’a pas remplacé les choix scientifiques, l’exécution des expériences ni la validation finale des résultats.

Où l’IA a été utilisée

- aide à la structuration de documents Markdown et LaTeX ;
- assistance ponctuelle pour du nettoyage, de la réorganisation et de la documentation du dépôt ;
- aide technique pour certains ajustements de code, de scripts et de notebooks ;
- proposition ou génération initiale de certaines portions de code, ensuite relues, modifiées, testées et validées humainement avant leur conservation.

Ce qui a été fait manuellement

- définition du sujet, des objectifs et du protocole expérimental ;
- choix des modèles, des variantes, des métriques et du cadre d’évaluation ;
- exécution des expériences, des notebooks et du pipeline ;
- relecture, correction et validation des portions de code retenues ;
- vérification des résultats numériques, des figures et de leur cohérence ;
- sélection des éléments retenus dans le rapport final ;

- interprétation scientifique des résultats et rédaction finale validée humainement.

7 Bibliographie

- Breiman, L. (2001). *Random forests*. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Cawley, G. C., & Talbot, N. L. C. (2010). *On over-fitting in model sélection and subsequent sélection bias in performance évaluation*. *Journal of Machine Learning Research*, 11, 2079-2107.
- Kaggle. (n.d.). *Leaf Classification*. <https://www.kaggle.com/c/leaf-classification>
- LeCun, Y., Bottou, L., Orr, G. B., & Muller, K.-R. (1998). *Efficient backprop*. In G. B. Orr & K.-R. Muller (Eds.), *Neural networks : Tricks of the trade* (pp. 9-50). Springer.
- Niculescu-Mizil, A., & Caruana, R. (2005). *Predicting good probabilities with supervised learning*. In *Proceedings of the 22nd International Conference on Machine Learning* (pp. 625-632).
- Platt, J. (1999). *Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods*. In A. J. Smola, P. Bartlett, B. Scholkopf, & D. Schuurmans (Eds.), *Advances in large margin classifiers* (pp. 61-74). MIT Press.
- scikit-learn developers. (n.d.). *DecisionTreeClassifier*. <https://scikit-learn.org/stable/modules/generated/sklearn.tree.DecisionTreeClassifier.html>
- scikit-learn developers. (n.d.). *F1 score*. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.f1_score.html
- scikit-learn developers. (n.d.). *Importance of feature scaling*. https://scikit-learn.org/stable/auto_examples/preprocessing/plot_scaling_importance.html
- scikit-learn developers. (n.d.). *LogisticRegression*. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html
- scikit-learn developers. (n.d.). *MLPClassifier*. https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html
- scikit-learn developers. (n.d.). *Model évaluation : Quantifying the quality of predictions*. https://scikit-learn.org/stable/modules/model_evaluation.html
- scikit-learn developers. (n.d.). *Nested versus non-nested cross-validation*. https://scikit-learn.org/stable/auto_examples/model_selection/plot_nested_cross_validation_iris.html
- scikit-learn developers. (n.d.). *PCA*. <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>
- scikit-learn developers. (n.d.). *Perceptron*. https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Perceptron.html
- scikit-learn developers. (n.d.). *Probability calibration*. <https://scikit-learn.org/stable/modules/calibration.html>
- scikit-learn developers. (n.d.). *RandomForestClassifier*. <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html>
- scikit-learn developers. (n.d.). *StandardScaler*. <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>
- scikit-learn developers. (n.d.). *SVC*. <https://scikit-learn.org/stable/modules>

[les/generated/sklearn.svm.SVC.html](#)

- Varma, S., & Simon, R. (2006). *Bias in error estimation when using cross-validation for model sélection*. *BMC Bioinformatics*, 7, Article 91.
<https://doi.org/10.1186/1471-2105-7-91>